

Extensión del sistema web de IAsLab: despliegue distribuido de modelos de inteligencia artificial, gobernanza y monitoreo de infraestructura

PROYECTO DE GRADO

Presentado como parte de los requisitos para obtener los títulos de
Ingeniero Telemático e Ingeniero de Sistemas

por

JUAN JOSE DE LA PAVA
Ingeniería Telemática e Ingeniería de Sistemas

JUAN DAVID PACHECO VARGAS
Ingeniería Telemática

JUAN CAMILO MELO
Ingeniería Telemática

Tutor: Kevin David Rodríguez Belalcázar
Profesor acompañante: Alejandro Muñoz Bravo

Departamento de Computación y Sistemas Inteligentes
Facultad Barberi de Ingeniería, Diseño y Ciencias Aplicadas

Universidad Icesi
2026

Índice general

Resumen	v
Abstract	vi
Lista de acrónimos	vii
Glosario de términos	viii
1 Motivación y antecedentes	1
1.1 Contexto	1
1.2 Antecedentes del problema	2
1.3 Justificación	3
2 Descripción del problema	5
2.1 Identificación del problema	5
2.2 Formulación del problema	5
3 Hipótesis y restricciones	6
3.1 Hipótesis	6
3.2 Restricciones	6
4 Objetivos	8
4.1 Objetivo general	8
4.2 Objetivos específicos	8
5 Marco teórico	10
6 Estado del arte	11
7 Metodología	12
7.1 Estrategia metodológica	12
7.2 Esquema de trabajo	13
7.3 Fases de desarrollo del proyecto	14
7.4 Análisis de riesgos y limitaciones	15
7.5 Presupuesto	16

8	Contribución y resultados del proyecto de grado	17
8.1	Aportes relacionados con el objeto del proyecto	17
8.2	Aportes relacionados con el desarrollo de capacidades del investigador	18
8.3	Resultados y entregables	18

Índice de tablas

7.1	Fases de desarrollo del proyecto y su correspondencia con los objetivos específicos. .	14
8.1	Trazabilidad entre objetivos específicos, resultados esperados y entregables.	19

Índice de figuras

Resumen

Palabras clave:

Abstract

Keywords:

Lista de acrónimos

AWQ Cuantización de pesos consciente de las activaciones (*Activation-aware Weight Quantization*)

CPU Unidad central de procesamiento (*Central Processing Unit*)

DCGM Gestor de GPU para centros de datos, de NVIDIA (*Data Center GPU Manager*)

DSR Investigación en ciencias del diseño (*Design Science Research*)

GGUF Formato de archivo para modelos cuantizados empleado por *llama.cpp* y Ollama

GPTQ Método de cuantización posterior al entrenamiento para modelos generativos preentrenados

GPU Unidad de procesamiento gráfico (*Graphics Processing Unit*)

IAsLab Laboratorio de Inteligencia Artificial y Arquitectura de Software de la Universidad Icesi

LLM Modelo extenso de lenguaje (*Large Language Model*)

MLOps Operaciones de aprendizaje automático (*Machine Learning Operations*)

PDG Proyecto de grado

RBAC Control de acceso basado en roles (*Role-Based Access Control*)

SAAMFI Servicio institucional de identidad y autenticación de la Universidad Icesi

SSO Inicio de sesión único (*Single Sign-On*)

SUS Escala de usabilidad del sistema (*System Usability Scale*)

VRAM Memoria de acceso aleatorio de video (*Video Random Access Memory*)

Glosario de términos

Capítulo 1

Motivación y antecedentes

1.1. Contexto

[TODO: Evitar escribir guiones largos (-) para evitar malentendidos sobre uso de IA] La operación de aprendizaje automático (MLOps) ha madurado hacia un ciclo de vida que excede la fase de entrenamiento de modelos. Sculley et al. (2015) advirtieron tempranamente que los sistemas de aprendizaje automático acumulan una deuda técnica oculta y específica del dominio —entrelazamiento de componentes, bucles de retroalimentación ocultos y consumidores no declarados de las señales que produce el modelo— que se manifiesta en las etapas posteriores al entrenamiento, cuando el modelo debe integrarse, servirse y monitorearse en producción. Revisiones posteriores han sistematizado este ciclo ampliado: Kreuzberger et al. (2023) proponen una arquitectura de referencia que articula entrenamiento, despliegue y monitoreo como componentes igualmente necesarios de MLOps, y Lima et al. (2022) documentan, mediante revisión sistemática de literatura, que la gobernanza de acceso, la asignación de cuotas y la telemetría de infraestructura son prácticas reconocidas del dominio, no responsabilidades accesorias del entrenamiento.

Este escenario general se concreta en el Laboratorio de Inteligencia Artificial y Arquitectura de Software (IASLab) de la Universidad Icesi, unidad que administra infraestructuras computacionales empleadas en proyectos académicos y de investigación en ciencia de datos e inteligencia artificial. El IASLab se enmarca en el macro-proyecto *Ecosistema computacional de servicios de software para el desarrollo de proyectos del IASLab para Industria 4.0 y e-Salud en el contexto de la Transformación Digital*, cuyo propósito es consolidar una plataforma institucional compartida para estas dos áreas prioritarias. Sobre esa infraestructura se construyó, en una primera fase, un sistema web diseñado como *control plane* que centraliza la configuración, ejecución y seguimiento de tareas de entrenamiento distribuido, integrando el mecanismo institucional de identidad SAAMFI para el aprovisionamiento seguro de nodos de procesamiento. Los involucrados directos de este ecosistema comprenden cinco roles con necesidades diferenciadas de cómputo: estudiantes que desarrollan su proyecto de grado, estudiantes de la electiva de inteligencia artificial, estudiantes de otras facultades que solicitan acceso puntual, integrantes de semilleros de investigación, y profesores investigadores y administradores del laboratorio responsables de la operación de la infraestructura.

La pertinencia de instrumentar con precisión el consumo de estos recursos compartidos no es una preocupación exclusiva del IAsLab. Gao et al. (2024), en un estudio empírico de Microsoft sobre 400 trabajos reales de entrenamiento, reportan una utilización promedio de GPU igual o inferior al 50 % en los trabajos estudiados, y establecen que el 84.99 % de los casos de baja utilización se explican por causas corregibles mediante cambios menores en el código. Esta cifra, obtenida en clústeres de escala industrial, ofrece una línea de base cuantitativa para argumentar que la subutilización de unidades de procesamiento gráfico (GPU) en entornos multiusuario es un fenómeno observable y medible, y no una percepción anecdótica, lo que justifica que el IAsLab busque dotar a su plataforma de mecanismos de observación y gobernanza equivalentes a los que documenta la literatura para clústeres de mayor escala.

1.2. Antecedentes del problema

[TODO: INCORPORAR ANTECEDENTE INSTITUCIONAL DE ACCESO A LOS EQUIPOS: Falta describir la realidad operativa e institucional que ha limitado el aprovechamiento del hardware en el IAsLab. Explicar cómo históricamente el acceso a los equipos y GPUs ha estado fuertemente restringido o concedido manualmente solo a ciertos miembros de confianza o investigadores principales del laboratorio. Aclarar la causa de esto: ante la falta de mecanismos automáticos de gobernanza, cuotas y aislamiento en el software, restringir el acceso directo era la única medida preventiva para evitar que procesos descontrolados saturaran o tumbaran la infraestructura. Relatar cómo esto creó un cuello de botella administrativo, tiempos de espera y la exclusión práctica de estudiantes de pregrado, semilleros y electivas, derivando en subutilización del hardware.]

El sistema web de la primera fase se concibió para resolver un cuello de botella concreto: la configuración manual de los nodos de cómputo y la subutilización de hardware que esta generaba, limitantes que restringían la escalabilidad y la reproducibilidad de los experimentos del laboratorio. Automatizar el aprovisionamiento de nodos y acoplarlo a la autenticación institucional resolvió ese problema puntual, pero dejó sin atender las etapas del ciclo de vida de MLOps que se sitúan después del entrenamiento. A medida que los proyectos del laboratorio avanzan, emerge la necesidad de habilitar el despliegue de modelos ya entrenados para su consumo, de garantizar una gestión equitativa del hardware conforme aumenta la concurrencia de usuarios, y de dotar al sistema de observabilidad técnica suficiente para diagnosticar su propio comportamiento.

[TODO: Evitar escribir guiones largos (-) para evitar malentendidos sobre uso de IA] La literatura sobre clústeres GPU compartidos confirma que estas tres carencias —servicio de inferencia, gobernanza de cuotas y observabilidad— son condiciones recurrentes de cualquier infraestructura multiusuario de aprendizaje automático, no problemas aislados del IAsLab. Jeon et al. (2019) analizaron dos meses de trazas del clúster Philly de Microsoft, con cerca de cien mil trabajos, y encontraron que la planificación por bloques (*gang scheduling*), las restricciones de localidad de datos y las fallas durante el entrenamiento producen colas prolongadas y baja utilización agregada. Gu et al. (2019) muestran, además, que los planificadores heredados de sistemas de procesamiento masivo de datos generan demoras significativas al aplicarse sin adaptación a cargas de aprendizaje

profundo. Esta falta de planificadores adaptados explica, en clave de causa y efecto, por qué el IAsLab no puede resolver la orquestación de inferencia ni la gobernanza de cuotas reutilizando mecanismos genéricos de colas: de ella se deriva la competencia desordenada por recursos y el riesgo de monopolización que ya se observa en el laboratorio conforme crece su comunidad de usuarios.

A esta ausencia de gobernanza se suma la falta de observabilidad fina del hardware, igualmente documentada en clústeres de producción. Weng et al. (2022) caracterizaron trazas de más de seis mil GPU en la plataforma Alibaba PAI, y Liu et al. (2022) muestran que trescientos cincuenta millones de registros de telemetría recolectados durante cuatro meses elevan la precisión de predicción de fallos de GPU del 46.3 % al 84.0 %. Estos estudios confirman que la telemetría de grano fino no es un refinamiento cosmético, sino la condición necesaria para diagnosticar saturaciones y anticipar fallos antes de que degraden el servicio, exactamente la limitación que hoy presenta el módulo de monitoreo primitivo del sistema web del IAsLab.

1.3. Justificación

Resolver estas carencias es pertinente porque el IAsLab sostiene, sobre una infraestructura física finita, proyectos de investigación y docencia que dependen de un acceso equitativo y predecible al cómputo. La ampliación del sistema hacia el despliegue de modelos, la gobernanza de cuotas y la observabilidad avanzada responde directamente a esa necesidad: sin un mecanismo de servicio de inferencia, la investigación entrenada en la plataforma no puede traducirse en un servicio consumible por sus propios usuarios, y sin cuotas ni telemetría, el crecimiento de la comunidad de usuarios del laboratorio pone en riesgo la disponibilidad del hardware para todos los involucrados por igual.

[TODO: Modelos de lenguaje extenso?] El proyecto es relevante, además, porque avances recientes y verificables en el servicio de modelos de lenguaje extenso (LLM) hacen viable su despliegue on-premise. Kwon et al. (2023) introdujeron PagedAttention, mecanismo central del motor vLLM, con una mejora de 2 a 4 veces en rendimiento de servicio a igual latencia; Yu et al. (2022) muestran que la programación por iteración (*continuous batching*) del sistema Orca alcanza una mejora de 36.9 veces frente a un motor de referencia. Estas ganancias se combinan con cuantización: Frantar et al. (2023) reducen un modelo de 175 mil millones de parámetros a 3–4 bits por peso en unas cuatro horas de cómputo, con degradación de precisión despreciable; Lin et al. (2024) reportan una aceleración superior a 3 veces frente a la implementación de referencia; y Dettmers et al. (2022) muestran que LLM.int8() reduce a la mitad la memoria necesaria para la inferencia sin pérdida perceptible de precisión. Esta evidencia sustenta que modelos de gran escala pueden servirse dentro de los 16 GB de VRAM de cada nodo del IAsLab, lo que hace viable su despliegue institucional en lugar de delegarlo a proveedores externos. **[TODO: Creo que no son 16GB de VRAM..]**

Esta última posibilidad conecta con un impacto adicional, de naturaleza académica y de privacidad de la información. Wiest et al. (2024) documentan que el uso de modelos de lenguaje basados en la nube exige transferir información privilegiada a servidores remotos, con riesgos legales y éticos en contextos sensibles, y validan un flujo de trabajo con un modelo ejecutado localmente como alternativa que preserva la privacidad de los datos. Trasladado al IAsLab, mantener la inferencia

sobre servidores propios de la Universidad Icesi salvaguarda la información de sus proyectos de investigación en Industria 4.0 y e-Salud, en lugar de exponerla a terceros. En el plano económico y de equidad, aprovechar la infraestructura ya instalada de la universidad evita que el acceso a modelos de gran escala dependa de suscripciones comerciales costeadas por cada estudiante. Esa dependencia condiciona la experiencia de aprendizaje a la capacidad de pago individual; al ofrecer el servicio sobre hardware institucional, el laboratorio nivela el acceso entre estudiantes con recursos económicos dispares.**[TODO: Evitar escribir guiones largos (-) para evitar malentendidos sobre uso de IA]** En conjunto, estos impactos —económico, académico y de privacidad— muestran que la extensión no solo resuelve una limitación interna, sino que aporta a la disciplina técnicas de inferencia de LLM que la literatura ha validado sobre todo en entornos de mayor escala.

[TODO: Revisar desde qué más puntos de vista se requieren especificar dentro del documento, se observa principalmente el impacto académico.]

Capítulo 2

Descripción del problema

2.1. Identificación del problema

El sistema web del IASLab presenta síntomas conforme los proyectos avanzan hacia las etapas productivas del ciclo de vida de MLOps (Capítulo 1). El síntoma principal es la fragmentación del flujo de trabajo: los investigadores entrenan modelos, pero carecen de un mecanismo integrado para desplegarlos y servir su inferencia, lo que impide traducir la investigación del laboratorio en servicios consumibles. La causa principal es la ausencia de un motor de orquestación de inferencia y de su interfaz; la secundaria, el desarrollo incremental del sistema, centrado en el entrenamiento.

Un segundo síntoma es el riesgo de monopolización de las unidades de procesamiento gráfico (GPU) conforme crece la adopción de la plataforma, condición ya documentada en clústeres compartidos (Capítulo 1). Su causa principal es la ausencia de gobernanza que imponga cuotas por rol; la secundaria, que SAAMFI autentica usuarios sin traducir el rol en límites de consumo de hardware. El efecto es la competencia desordenada por recursos entre pregrado, electiva, semilleros y profesores investigadores, con riesgo de desplazar tareas exploratorias de tesis o semillero. Un tercer síntoma técnico es la telemetría primitiva del monitoreo, que impide observar el consumo en tiempo real y dificulta diagnosticar saturaciones. Subsiste, además, un backlog de historias de usuario que compromete la estabilidad del software.

2.2. Formulación del problema

El sistema carece de un mecanismo para desplegar y servir la inferencia de modelos ya entrenados, y no incorpora gobernanza de cuotas por rol ni telemetría granular en tiempo real, lo que fragmenta el ciclo de MLOps y expone la plataforma a un uso inequitativo de recursos. De ello se deriva la pregunta que orienta el proyecto: ¿cómo extender el sistema para incorporar despliegue e inferencia distribuida, gobernanza de cuotas por rol y observabilidad avanzada, sin comprometer su estabilidad ni disponibilidad? Responderla es pertinente y relevante porque consolida, en una sola plataforma, las etapas hoy desarticuladas de entrenamiento, despliegue y monitoreo.

Capítulo 3

Hipótesis y restricciones

3.1. Hipótesis

Se plantea como hipótesis de ingeniería que un motor de orquestación de inferencia agnóstico a la tecnología subyacente, acoplado a una gobernanza de cuotas por rol *Fair-Share* y a telemetría fina, permite extender el sistema web del IAsLab hacia una plataforma que sostenga despliegue, gobernanza y monitoreo de MLOps sin degradar el desempeño ni la disponibilidad de la fase de entrenamiento. Es plausible: la primera fase ya demostró que un control plane centralizado, apoyado en SAAMFI, resuelve problemas equivalentes, y reutilizar ese patrón evita un paradigma no probado. Es además falsable mediante pruebas de carga y validaciones de usabilidad (objetivo específico 4): una degradación del desempeño o una aceptación insatisfactoria la refutarían.

3.2. Restricciones

Las restricciones que se enumeran a continuación condicionan el alcance, la calidad o el cronograma del proyecto. Se distinguen de los supuestos, que son condiciones externas sobre las que el proyecto no tiene control directo y que se presentan por separado al cierre de esta sección.

Despliegue estrictamente on-premise El sistema opera dentro de la infraestructura física del IAsLab, sin recurrir a proveedores de nube pública comercial. Afecta el alcance y la calidad, pues descarta los patrones de escalado elástico y obliga a diseñar la orquestación para un parque de hardware finito y conocido de antemano.

Capacidad de VRAM limitada por nodo Cada nodo de inferencia dispone de una GPU NVIDIA RTX 4080 con 16 GB de VRAM. Afecta el alcance y la calidad, ya que obliga a cuantizar los modelos y acota el tamaño y la precisión de los que la plataforma puede servir de forma concurrente.

Exclusión del desarrollo de modelos propios El proyecto no contempla el diseño de arquitecturas de redes neuronales ni de algoritmos subyacentes: se limita a orquestar modelos preentrenados de código abierto. Afecta el alcance, delimitando el trabajo a la capa de infraestructura y orquestación.

Límites de red y capacidad física del laboratorio La red interna del campus y la capacidad instalada imponen un techo al tráfico y a la concurrencia sostenibles. Afecta la calidad y el cronograma, porque condiciona el diseño de las pruebas de carga a los límites reales de la infraestructura.

Base de código heredada La extensión se construye sobre el código resultante de la fase de entrenamiento, que arrastra un backlog de historias de usuario sin resolver. Afecta el cronograma, pues parte del esfuerzo se destina a estabilizar componentes existentes antes de incorporar capacidades nuevas.

[**TODO: Revisar características de los computadores nuevamente, este apartado es nuevo, lo están solicitando dentro del formato de PDG? Interesante pero quizá hace parte de los anexos.**]

Adicionalmente, el proyecto asume dos condiciones externas: la disponibilidad ininterrumpida de los clústeres del IAsLab durante las pruebas y la persistencia del servicio institucional de autenticación SAAMFI. Su incumplimiento retrasaría las actividades de validación y comprometería la gobernanza de cuotas por rol, que depende de los atributos que ese servicio provee.

Capítulo 4

Objetivos

4.1. Objetivo general

[**TODO: Se quiere consolidar o se quiere extender? Evitar especificar dos verbos dentro del objetivo, evitar especificar fechas como .°cho meses**] Extender el sistema web de orquestación del IAsLab con despliegue distribuido de IA, gobernanza de recursos por rol y observabilidad avanzada de infraestructura, para consolidar el ciclo de vida de MLOps on-premise en la Universidad Icesi, en ocho meses.

4.2. Objetivos específicos

[**TODO: Primer objetivo específico demasiado detallado, podría ser incluso un objetivo general, evitar usar palabras ambiguas como "interactivas", se puede evitar los aspectos que están entre paréntesis. Evitar especificar varios verbos en un solo objetivo. Ej: Desarrollar un módulo de observabilidad en el sistema web del IAsLab para la captura y visualización de métricas de hardware y de inferencia, orientado a la supervisión del estado de los nodos de cómputo.]**

1. Ampliar el módulo de telemetría del IAsLab con visualizaciones interactivas de métricas de hardware (temperatura, VRAM, consumo energético) e inferencia (latencia, *tokens* por segundo, saturación de concurrencia), con el fin de que los administradores observen en tiempo real el consumo y diagnostiquen fallos antes de afectar a otros usuarios. Se considera “tiempo real” que las métricas expuestas reflejen el estado de la infraestructura dentro de una ventana no mayor a cinco minutos, criterio que se verificará en el objetivo específico 4.
2. [**TODO: Solo se va a diseñar o también desarrollar?**] Diseñar un esquema lógico de cuotas y restricciones de infraestructura acoplado a los atributos de rol de SAAMFI (pregado, electiva, semilleros y profesores), bajo el principio *Fair-Share*, con el fin de prevenir la monopolización de las GPU conforme crece la concurrencia de usuarios.

3. **[TODO:Cuál es esa interfaz del IASLab?]** Integrar en la interfaz del IASLab un motor de orquestación de inferencia independiente de la tecnología subyacente, que permita desplegar modelos ya entrenados de forma concurrente, con el fin de habilitarlos en la misma plataforma usada para el entrenamiento.
4. **[TODO: Evitar generar ambigüedades, en los objetivos no se agregan elementos como el de "verify: ADR-004 ...]** Evaluar el desempeño de la extensión en producción mediante pruebas de carga y validaciones de usabilidad con usuarios del laboratorio, con el fin de determinar si alcanza una aceptación satisfactoria *[verify: ADR-004 — criterio cuantitativo de aceptación operacional, no especificado en project-context/]*.

Capítulo 5

Marco teórico

Capítulo 6

Estado del arte

Capítulo 7

Metodología

[TODO: Evitar usar guiones largos.] Este capítulo formula y justifica la metodología de ingeniería adoptada para resolver el problema planteado en el Capítulo 2, describe la estructura lógica del proceso de investigación —desde la recolección de datos hasta la presentación de resultados—, delimita el esquema de trabajo con el tutor, define las fases de desarrollo del proyecto en relación directa con los objetivos específicos del Capítulo 4, y analiza los riesgos y limitaciones que pueden afectar su alcance, cronograma, presupuesto y calidad.

7.1. Estrategia metodológica

[TODO: Tener cuidado con enmarcar el proyecto en metodologías y reglas que ustedes pueden no aplicar, si se mencionan es porque existe una labor detrás de comprender los aspectos metodológicos y detallarlos como se debe, si no esperan hacer algo así, no mencionarlo.] El proyecto se enmarca dentro de *Design Science Research* (DSR), un paradigma de investigación orientado a la construcción y evaluación de artefactos de software que resuelven un problema organizacional identificado. Hevner et al. (2004) formulan siete guías para la investigación en Sistemas de Información bajo este paradigma, entre ellas que el artefacto producido debe ser relevante para un problema organizacional real y que su utilidad debe demostrarse mediante una evaluación rigurosa; ambas condiciones se cumplen en este proyecto, pues la extensión del sistema web del IAsLab constituye un artefacto de software concreto —el motor de orquestación de inferencia, el módulo de cuotas y el módulo de telemetría ampliado— que responde a una necesidad operativa documentada del laboratorio y cuya utilidad se contrastará empíricamente mediante las pruebas de carga y usabilidad descritas más adelante. Para ordenar la ejecución del proyecto se adopta, además, el proceso de seis pasos de Peffers et al. (2007): identificación del problema y motivación, definición de los objetivos de una solución, diseño y desarrollo del artefacto, demostración, evaluación, y comunicación de resultados. Esta secuencia es coherente con la estructura del presente documento, en la que los Capítulos 2 y 4 cubren los dos primeros pasos, las fases descritas en la Apartado 7.3 cubren el diseño, el desarrollo y la demostración, y la evaluación de desempeño y usabilidad prevista en objetivo específico 4 cierra el ciclo antes de la comunicación

de resultados en el informe final del proyecto de grado.

Design Science Research define el marco investigativo del proyecto, pero no prescribe cómo organizar el trabajo de ingeniería día a día; para ello se adopta un proceso de desarrollo iterativo-incremental de tipo Scrum, siguiendo la *Scrum Guide* de Schwaber and Sutherland (2020). Esta elección responde a que el alcance del proyecto —cuatro objetivos específicos con dependencias técnicas parciales entre sí (telemetría, gobernanza, orquestación y evaluación)— se beneficia de ciclos cortos de construcción y retroalimentación sobre un backlog heredado cuya estabilización, según se documentó en el Capítulo 3, es en sí misma una condición previa al desarrollo de las capacidades nuevas. Un proceso iterativo permite priorizar y reordenar el backlog conforme se estabiliza el código heredado y conforme la disponibilidad de los clústeres del IAsLab lo permita, en lugar de comprometer de antemano una secuencia rígida de actividades como exigiría un modelo de desarrollo en cascada.

La estructura lógica del proceso de investigación se organiza en cuatro etapas. La recolección de datos se apoya en tres fuentes instrumentadas por el propio sistema: la telemetría de hardware e inferencia que produce el módulo de observabilidad ampliado (objetivo específico 1), los resultados que genera el motor de *benchmarking* automatizado sobre los nodos de inferencia, y los instrumentos de usabilidad aplicados a los usuarios finales de la plataforma. La organización y sistematización de estos datos consiste en consolidar las métricas de hardware, de inferencia y de percepción de usuario en formatos comparables entre fases y entre motores de inferencia evaluados. El análisis contrasta estas métricas contra los objetivos específicos formulados, determinando en qué medida cada módulo construido resuelve la carencia que motivó su desarrollo. Finalmente, la interpretación y presentación de resultados traduce los hallazgos del análisis en conclusiones sobre el cumplimiento de la hipótesis de ingeniería del Capítulo 3 y sobre el nivel de aceptación operacional de la extensión.

La evaluación empírica prevista en objetivo específico 4 se apoya en dos instrumentos con respaldo metodológico propio. Para el desempeño técnico, el proyecto recurre a pruebas de carga sobre los nodos de inferencia; Jiang and Hassan (2015), en su revisión de la literatura sobre pruebas de carga en sistemas de gran escala, sistematizan el diseño de la carga, su ejecución y el análisis de los resultados obtenidos, estructura que este proyecto sigue para contrastar el comportamiento de los motores de inferencia desplegados bajo concurrencia realista de usuarios. Para la aceptación operacional por parte de los usuarios finales, se emplea el *System Usability Scale* de Brooke (1996), un cuestionario de diez ítems ampliamente validado como instrumento estándar para cuantificar la usabilidad percibida de un sistema de software, aplicable a los distintos roles de usuario del IAsLab identificados en el Capítulo 1.

7.2. Esquema de trabajo

[TODO: No es necesario mencionar explícitamente cuántos estudiantes de trabajo son, este apartado puede borrarse por completo, habla del proceso del curso de pdg mas no del proyecto en si] El proyecto lo desarrolla un equipo de tres estudiantes que trabaja bajo un esquema de responsabilidad compartida: en lugar de asignar cada módulo a un integrante, los tres participan en la implementación de los subsistemas, en la ejecución de las pruebas y en la

redacción del documento. Este esquema es coherente con el carácter formativo del proyecto de grado, en el que cada integrante debe desarrollar las competencias asociadas a la totalidad del trabajo y no solo a una de sus partes, y resulta viable dado el tamaño del equipo, que hace innecesaria una división formal de roles para coordinar el trabajo.

El seguimiento se realiza mediante una reunión semanal con el tutor del proyecto, en la que se revisa el avance de la iteración en curso y se ajusta el alcance de la siguiente. Esta cadencia se articula con el proceso iterativo descrito en la Apartado 7.1 y proporciona el punto de control periódico que permite detectar desviaciones frente a las fases planificadas.

7.3. Fases de desarrollo del proyecto

Las fases de desarrollo del proyecto guardan una relación directa con los objetivos específicos formulados en el Capítulo 4, de modo que cada fase produce el artefacto o el resultado necesario para satisfacer uno de ellos. La primera fase corresponde al análisis y la estabilización del backlog heredado de la primera etapa del sistema web, condición previa identificada en el Capítulo 3 antes de incorporar cualquier capacidad nueva sobre el código existente. Las fases siguientes desarrollan, en orden, el módulo de observabilidad, el esquema de gobernanza de cuotas y el motor de orquestación de inferencia, y cierran con la fase de evaluación empírica que contrasta los tres módulos anteriores contra los objetivos que les dieron origen. La Tabla 7.1 resume esta correspondencia.

[TODO: Dicen que habrá una fase de análisis y estabilización del backlog heredado, será así?. Primero se trabajará la observabilidad de infraestructura y luego la de orquestación y gobernanza? Revisar el orden cronológico que se espera de las fases.]

Cuadro 7.1: *Fases de desarrollo del proyecto y su correspondencia con los objetivos específicos.*

Fase	Actividades principales	Objetivo específico
Análisis y estabilización del backlog heredado	Revisión del backlog de historias de usuario pendientes de la primera fase del sistema web, priorización y resolución de los ítems que condicionan la estabilidad del código base sobre el que se construyen las fases siguientes	Condición previa (Capítulo 3)
Observabilidad de infraestructura	Instrumentación y ampliación del módulo de telemetría con métricas de hardware e inferencia por nodo, y construcción de las visualizaciones gráficas interactivas correspondientes	Objetivo específico 1
Gobernanza de cuotas	Diseño del esquema lógico de cuotas y restricciones de infraestructura acoplado a los atributos de rol de SAAMFI bajo el principio <i>Fair-Share</i> , e integración con el módulo administrativo de la plataforma	Objetivo específico 2

Fase	Actividades principales	Objetivo específico
Orquestación de inferencia	Integración del motor de orquestación de inferencia independiente de la tecnología subyacente y de la interfaz web para configurar y desplegar modelos entrenados de forma concurrente	Objetivo específico 3
Evaluación empírica	Ejecución de pruebas de carga sobre los nodos de inferencia mediante el motor de <i>benchmarking</i> automatizado y aplicación de instrumentos de usabilidad (System Usability Scale) con usuarios finales	Objetivo específico 4

7.4. Análisis de riesgos y limitaciones

[TODO: Por que el análisis de riesgos y limitaciones está en el capítulo de metodología? Revisar el formato entregado por el curso de PDG, quizá esto va en anexos.] Los riesgos que se describen a continuación se derivan de las restricciones y los supuestos ya enunciados en el Capítulo 3, sin duplicar su argumentación, y se presentan junto con la dimensión del proyecto que comprometen y la estrategia prevista para mitigarlos.

[TODO: "Falta de disponibilidad" podría ser mejor. En el documento debe dejarse claro qué es SAAMFI, puede estar en el estado de la práctica. Borrarr el riesgfo de "Dificultad para reclutar usuarios finales en las validaciones de usabilidad." Deben de repensar cuáles serían los riesgos y limitaciones. Borrarr capítulo de presupuesto.]

Indisponibilidad de los clústeres del IAsLab Compromete el cronograma, dado que las fases de desarrollo y, en particular, la evaluación empírica dependen del acceso continuo a los nodos de cómputo del laboratorio, condición que el Capítulo 3 asume vigente pero no controla directamente. Como estrategia de mitigación, las actividades de desarrollo que no requieren hardware de inferencia (por ejemplo, la definición del esquema lógico de cuotas) se priorizan en los periodos de menor disponibilidad de los clústeres.

Cambios o caída del servicio SAAMFI Compromete el alcance y el cronograma, pues el control de acceso y la gobernanza de cuotas por rol dependen de los atributos que provee este servicio institucional de identidad. La mitigación consiste en aislar la lógica de mapeo de roles en un componente propio de la extensión, de modo que un cambio en la interfaz de SAAMFI exija ajustar ese componente y no rediseñar el esquema de cuotas completo.

Saturación de VRAM y eventos de congelamiento en nodos GPU Compromete la calidad del servicio de inferencia y, potencialmente, el cronograma de las pruebas de carga, ya que la saturación de memoria de video o el congelamiento de un nodo GPU (FR-03.4) puede interrumpir sesiones de otros usuarios concurrentes. Liu et al. (2022) documentan que este tipo de fallos es predecible con telemetría suficiente en producción, por lo que la mitigación

prevista es que el módulo de observabilidad (objetivo específico 1) genere las alertas de diagnóstico automatizado que exige FR-03.4 antes de que la saturación derive en una interrupción no controlada.

Esfuerzo del backlog heredado mayor al previsto Compromete el cronograma y el alcance de las fases posteriores, en la medida en que la fase de estabilización descrita en la Apartado 7.3 podría absorber más tiempo del proyectado si el backlog heredado presenta una deuda técnica mayor a la esperada. La mitigación consiste en delimitar de forma temprana, dentro de la fase de estabilización, qué ítems del backlog son estrictamente bloqueantes para las fases de gobernanza y orquestación, y cuáles pueden diferirse.

Dificultad para reclutar usuarios finales en las validaciones de usabilidad Compromete la calidad de la evidencia recogida para objetivo específico 4, pues la aplicación del *System Usability Scale* (Brooke, 1996) requiere la participación voluntaria de estudiantes, semilleros e investigadores cuya disponibilidad no está garantizada. La mitigación consiste en distribuir la aplicación del instrumento entre los distintos roles de usuario identificados en el Capítulo 1, de modo que la muestra no dependa de un único grupo.

Límites de ancho de banda del campus Compromete la calidad de las pruebas de carga, en tanto la red interna de la Universidad Icesi impone un techo de tráfico y concurrencia distinto al que tendría un entorno de nube pública sin esa restricción, condición ya señalada como límite físico en el Capítulo 3. La mitigación consiste en diseñar los escenarios de prueba de carga a partir de la capacidad real medida de la red institucional, en lugar de extrapolar cifras de referentes de la literatura obtenidos en infraestructuras de mayor escala.

7.5. Presupuesto

El proyecto no requiere presupuesto propio. El trabajo consiste en desplegar y poner en funcionamiento el clúster sobre la infraestructura ya instalada en el laboratorio, sin adquisición de hardware nuevo, y la totalidad del software empleado —Kubernetes, KubeRay, vLLM, Ollama, LiteLLM, Prometheus, Grafana y Loki— es de código abierto. La restricción de operar estrictamente on-premise, señalada en el Capítulo 3, elimina además cualquier gasto recurrente por servicios de nube pública. En consecuencia, los únicos recursos comprometidos son el tiempo de los integrantes del equipo y el uso del equipamiento existente del IAsLab.

Capítulo 8

Contribución y resultados del proyecto de grado

[TODO: Con el objeto del proyecto? Revisar si este capitulo ha sido solicitado por el profesor de PDG como parte del formato. Falta el cronograma dentro de este documento.]

8.1. Aportes relacionados con el objeto del proyecto

La extensión descrita en los capítulos anteriores incide directamente sobre el problema formulado en Capítulo 2: la fragmentación del ciclo de vida de MLOps y el riesgo de uso inequitativo de la infraestructura del IAsLab. Su primer aporte es de naturaleza institucional y económica. Al habilitar el despliegue distribuido de modelos ya entrenados sobre el mismo hardware que hoy se usa para el entrenamiento, el proyecto maximiza el retorno de la inversión realizada en la infraestructura del laboratorio, en lugar de dejarla limitada a la fase experimental del ciclo de vida. El esquema de cuotas y gobernanza acoplado a los roles institucionales, por su parte, democratiza el acceso a las unidades de procesamiento gráfico entre estudiantes de pregrado, cursantes de la electiva, semilleros de investigación y profesores investigadores, evitando el acaparamiento de recursos críticos por parte de un único grupo de usuarios. Esta misma capacidad reduce la necesidad de adquirir créditos de cómputo en nubes públicas comerciales para sostener cargas de trabajo que la infraestructura on-premise del laboratorio puede absorber de forma equitativa, argumento que se desarrolla en Capítulo 1.

En el plano académico, el proyecto habilita la ejecución de proyectos avanzados en áreas prioritarias para el macro-proyecto, como Industria 4.0 y e-Salud, al permitir que arquitecturas de gran escala —en particular modelos de lenguaje extenso— pasen de la fase de entrenamiento a un servicio de inferencia consumible dentro de la misma plataforma institucional. Esta capacidad tiene además una implicación de privacidad y gobernanza de datos: al mantener el procesamiento de inferencia sobre servidores propios del IAsLab, en lugar de delegarlo en proveedores externos, la información asociada a estos proyectos de investigación permanece bajo el control administrativo de la universidad. Finalmente, en el plano operativo, la ampliación del módulo de telemetría y la administración centralizada de cuotas reducen la carga cognitiva y administrativa que hoy recae

sobre los administradores del laboratorio, quienes actualmente carecen de visibilidad granular sobre el consumo real de la infraestructura para diagnosticar saturaciones o conflictos de uso entre usuarios.

8.2. Aportes relacionados con el desarrollo de capacidades del investigador

La ejecución de este proyecto por parte del equipo de tres estudiantes de Ingeniería de Sistemas exige y desarrolla competencias profesionales específicas de la disciplina, distintas de las requeridas en la primera fase del sistema web del IAsLab. La integración del motor de orquestación de inferencia sobre Kubernetes y KubeRay/Ray, junto con la definición de reglas de selección de nodos y aislamiento de cargas de trabajo, desarrolla competencias de orquestación de contenedores y cómputo distribuido en topologías heterogéneas de CPU y GPU. La adaptación de motores de servicio como vLLM y de esquemas de cuantización de modelos (AWQ, GPTQ, GGUF) para maximizar la concurrencia dentro de la memoria de video disponible desarrolla, adicionalmente, competencias de ingeniería de plataformas de inferencia y de optimización de modelos bajo restricciones de hardware.

El diseño del esquema lógico de cuotas bajo el principio de *Fair-Share*, acoplado a los atributos de rol expuestos por el servicio de identidad institucional SAAMFI, exige competencias de diseño de esquemas de gobernanza y de integración con sistemas de control de acceso basado en roles (RBAC), un dominio propio de la ingeniería de software orientada a sistemas multiusuario. La construcción del módulo de observabilidad avanzada, apoyado en Prometheus, Grafana, Loki y el exportador DCGM de NVIDIA, desarrolla competencias de ingeniería de observabilidad de infraestructura distribuida, entendida como la capacidad de instrumentar, recolectar y visualizar métricas de hardware e inferencia en tiempo real. Por último, la evaluación de la extensión mediante pruebas de carga sobre los nodos de inferencia, un motor de *benchmarking* automatizado y validaciones de usabilidad con usuarios reales desarrolla competencias de diseño y ejecución de evaluación empírica de sistemas de software, indispensables para sustentar decisiones de ingeniería con evidencia y no solo con criterio de diseño.

8.3. Resultados y entregables

De acuerdo con el formato institucional del anteproyecto, cada resultado esperado y su entregable correspondiente deben trazarse a al menos uno de los objetivos específicos formulados en Capítulo 4. La Tabla 8.1 presenta esta trazabilidad para los cuatro objetivos específicos del proyecto.

Cuadro 8.1: Trazabilidad entre objetivos específicos, resultados esperados y entregables.

Objetivo específico	Resultado esperado	Entregable
Objetivo específico 1: ampliación del módulo de telemetría	Panel de telemetría ampliado que muestra, por nodo, métricas de hardware (temperatura, VRAM, consumo energético) y de inferencia (latencia, <i>tokens</i> por segundo, saturación de concurrencia) mediante visualizaciones gráficas interactivas	Módulo de observabilidad integrado al sistema web (Prometheus, DCGM Exporter, Grafana, Loki) y su documentación de despliegue
Objetivo específico 2: gobernanza de cuotas por rol	Esquema lógico de cuotas y restricciones de infraestructura operando bajo el principio <i>Fair-Share</i> y acoplado a los roles provistos por SAAMFI	Módulo administrativo de gestión de cuotas integrado a la plataforma web y manual de administración de políticas de cuotas
Objetivo específico 3: orquestación de despliegue de inferencia	Motor de orquestación de inferencia, independiente de la tecnología subyacente, capaz de configurar y desplegar modelos entrenados de forma concurrente desde la interfaz web	Interfaz de despliegue de modelos integrada al sistema web y manual de despliegue de modelos
Objetivo específico 4: evaluación de desempeño y aceptación	Reporte de desempeño de la extensión bajo pruebas de carga sobre los nodos de inferencia y de aceptación operacional mediante validaciones de usabilidad con estudiantes, semilleros e investigadores	Informe de resultados de pruebas de carga y usabilidad, con los datos generados por el motor de <i>benchmarking</i> automatizado

Los cuatro entregables específicos de la Tabla 8.1 convergen en los dos entregables globales exigidos para el proyecto de grado. El primero es el software funcional y empaquetado: el código fuente de la extensión del sistema web, desplegado sobre la infraestructura propia del IAsLab y estructurado bajo estándares que permitan su registro como producto tecnológico con derechos de autor. El segundo es la documentación técnica y de usuario actualizada, compuesta por los manuales de despliegue de modelos, de visualización de telemetría y de administración de políticas de cuotas que se derivan de cada uno de los módulos anteriores. Ambos entregables globales dependen del cumplimiento conjunto de los cuatro objetivos específicos: ninguno de los módulos —telemetría, gobernanza, orquestación o evaluación— constituye por sí solo el sistema extendido que exige el objeto del proyecto.

Bibliografía

- Brooke, J. (1996). SUS: A quick and dirty usability scale. Technical report, Redhatch Consulting Ltd. In P. W. Jordan, B. Thomas, B. A. Weerdmeester, & A. L. McClelland (Eds.), *Usability Evaluation in Industry*, CRC Press, London.
- Dettmers, T., Lewis, M., Belkada, Y., and Zettlemoyer, L. (2022). LLM.int8(): 8-bit matrix multiplication for transformers at scale. In *Advances in Neural Information Processing Systems 35 (NeurIPS 2022)*. Curran Associates, Inc.
- Frantar, E., Ashkboos, S., Hoefler, T., and Alistarh, D. (2023). GPTQ: Accurate post-training quantization for generative pre-trained transformers. In *Proceedings of the 11th International Conference on Learning Representations (ICLR 2023)*.
- Gao, Y., He, Y., Li, X., Zhao, B., Lin, H., Liang, Y., Zhong, J., Zhang, H., Wang, J., Zeng, Y., Gui, K., Tong, J., and Yang, M. (2024). An empirical study on low GPU utilization of deep learning jobs. In *Proceedings of the IEEE/ACM 46th International Conference on Software Engineering (ICSE 2024)*. ACM.
- Gu, J., Chowdhury, M., Shin, K. G., Zhu, Y., Jeon, M., Qian, J., Liu, H., and Guo, C. (2019). Tiresias: A GPU cluster manager for distributed deep learning. In *Proceedings of the 16th USENIX Symposium on Networked Systems Design and Implementation (NSDI 19)*, pages 485–500. USENIX Association.
- Hevner, A. R., March, S. T., Park, J., and Ram, S. (2004). Design science in information systems research. *MIS Quarterly*, 28(1):75–105.
- Jeon, M., Venkataraman, S., Phanishayee, A., Qian, J., Xiao, W., and Yang, F. (2019). Analysis of large-scale multi-tenant GPU clusters for DNN training workloads. In *Proceedings of the 2019 USENIX Annual Technical Conference (USENIX ATC 19)*. USENIX Association.
- Jiang, Z. M. and Hassan, A. E. (2015). A survey on load testing of large-scale software systems. *IEEE Transactions on Software Engineering*, 41(11):1091–1118.
- Kreuzberger, D., Kühn, N., and Hirschl, S. (2023). Machine learning operations (MLOps): Overview, definition, and architecture. *IEEE Access*, 11:31866–31879.
- Kwon, W., Li, Z., Zhuang, S., Sheng, Y., Zheng, L., Yu, C. H., Gonzalez, J. E., Zhang, H., and Stoica, I. (2023). Efficient memory management for large language model serving with PagedAttention. In *Proceedings of the 29th ACM Symposium on Operating Systems Principles (SOSP 23)*. ACM.

- Lima, A., Monteiro, L., and Furtado, A. P. (2022). MLOps: Practices, maturity models, roles, tools, and challenges – a systematic literature review. In *Proceedings of the 24th International Conference on Enterprise Information Systems (ICEIS 2022)*, pages 308–320. SciTePress.
- Lin, J., Tang, J., Tang, H., Yang, S., Chen, W.-M., Wang, W.-C., Xiao, G., Dang, X., Gan, C., and Han, S. (2024). AWQ: Activation-aware weight quantization for on-device LLM compression and acceleration. In *Proceedings of the 7th Conference on Machine Learning and Systems (MLSys 2024)*. Best Paper Award.
- Liu, H., Li, Z., Tan, C., Yang, R., Cao, G., Liu, Z., and Guo, C. (2022). Prediction of GPU failures under deep learning workloads. *arXiv preprint arXiv:2201.11853*.
- Peppers, K., Tuunanen, T., Rothenberger, M. A., and Chatterjee, S. (2007). A design science research methodology for information systems research. *Journal of Management Information Systems*, 24(3):45–77.
- Schwaber, K. and Sutherland, J. (2020). The scrum guide: The definitive guide to scrum: The rules of the game.
- Sculley, D., Holt, G., Golovin, D., Davydov, E., Phillips, T., Ebner, D., Chaudhary, V., Young, M., Crespo, J.-F., and Dennison, D. (2015). Hidden technical debt in machine learning systems. In *Advances in Neural Information Processing Systems 28 (NeurIPS 2015)*. Curran Associates, Inc.
- Weng, Q., Xiao, W., Yu, Y., Wang, W., Wang, C., He, J., Li, Y., Zhang, L., Lin, W., and Ding, Y. (2022). MLaaS in the wild: Workload analysis and scheduling in large-scale heterogeneous GPU clusters. In *Proceedings of the 19th USENIX Symposium on Networked Systems Design and Implementation (NSDI 22)*, pages 945–960. USENIX Association.
- Wiest, I. C., Ferber, D., Zhu, J., van Treeck, M., Meyer, S. K., Juglan, R., Carrero, Z. I., Paech, D., Kleesiek, J., Ebert, M. P., Truhn, D., and Kather, J. N. (2024). Privacy-preserving large language models for structured medical information retrieval. *npj Digital Medicine*, 7:257.
- Yu, G.-I., Jeong, J. S., Kim, G.-W., Kim, S., and Chun, B.-G. (2022). Orca: A distributed serving system for transformer-based generative models. In *Proceedings of the 16th USENIX Symposium on Operating Systems Design and Implementation (OSDI 22)*. USENIX Association.